سوال ۱. با استفاده از فرض همگرایی و یکتا بودن بردار مربوط به حالت ایستا، داریم:

$$\pi_{\infty} = \pi_{\infty+1}$$

پس

$$\pi_{\infty} = \pi_{\infty} P$$

$$\pi(i) = \Sigma_{j=1}^k \pi(j) P_{ji} \ x = [x_1, x_1, x_2, ..., x_k]$$

$$\sum_{j=1}^k \pi(j) = 1$$

اگر توزیع یکنواخت را $\pi_{\infty}=[rac{1}{k},...,rac{1}{k}]$ پس داریم π_{∞} اگر توزیع یکنواخت را

$$\sum_{i=1}^{k} \frac{1}{k} P_{ij} = \frac{1}{k} = x_j$$

پس در نهایت برای توزیع یونیفرم x داریم:

$$xP = x$$

و x همان حالت ایستای چنین ماتریس انتقالی است.

f(1) سوال ۲. به محاسبه ی نقاط مرزی تابع که بپردازیم می بینیم که مقادیر f(t) و f(t) برابر با t هستند. حالا مقادیر و f(t) و f(t) و f(t) را محاسبه می کنیم با توجه به این که هر سطر احتمال رفتن به دیگر حالت ها را می دهد.

$$f(\mathbf{1}) = p(\mathbf{1} + \boldsymbol{\cdot}) + q(\mathbf{1} + f(\mathbf{1})) = p + q + qf(\mathbf{1}) = \mathbf{1} + qf(\mathbf{1})$$

$$f(Y) = p(Y + f(Y)) + q(Y + f(Y)) = p + q + pf(Y) + qf(Y) = Y + pf(Y) + qf(Y)$$

$$f(\mathbf{Y}) = p(\mathbf{Y} + f(\mathbf{Y})) + q(\mathbf{Y} + \mathbf{Y}) = p + q + pf(\mathbf{Y}) = \mathbf{Y} + pf(\mathbf{Y})$$

پس بدست مي آوريم:

$$f(1) = 1 + \frac{Yq}{q - Ypq}$$

$$f(\Upsilon) = \frac{\Upsilon}{1 - \Upsilon pq}$$

$$f(\mathbf{Y}) = \mathbf{1} + \frac{\mathbf{Y}p}{\mathbf{1} - \mathbf{Y}pq}$$

پس در نهایت مقدار هر کدام میشود:

$$f(1) = \Upsilon$$

$$f(Y) = Y$$

$$f(\Upsilon) = 1$$

و داريم:

$$f(n) = \mathbf{f}n - n^{\mathbf{f}}$$

سوال ٣.

الف

تعداد پارامترهای لازم در این بخش برابر است با پارامترهای بردار اولیه به علاوهی پارامترهای مورد نیاز برای ماتریس انتقال و همچنین نشان دادن احتمال مربوط به مشاهدات:

$$k^{\mathsf{T}} + k + km$$

ب

الگوریتم Forward یکی از الگوریتمهای مهم در حوزه بیزین (Bayesian) است و برای تخمین احتمالات پسین (posterior probabilities) متغیرهای نهان در مدلهای گرافیکی بیزین استفاده می شود.

این الگوریتم برای محاسبه احتمالات پسین متغیرهای نهان با استفاده از دادههای مشاهده شده به کار میرود. به طور کلی، الگوریتم Forward بر اساس فرآیند تکراری اطلاعات جدید را درباره احتمالات پسین بروز میدهد.

برای شروع، احتمال پیشین (prior probability) متغیرهای نهان را تعیین میکنیم. سپس با استفاده از این احتمال پیشین و اطلاعات مشاهده شده، احتمالات پیشین تا زمان فعلی را محاسبه میکنیم.

با توجه به الگوریتم forward و توالی اتفاقات، احتمال هر کدام را مینویسیم.

$$P(A,O_1) = \cdot / \Lambda \times \cdot / 44 = \cdot / V4Y$$

$$P(B, O_1) = \cdot / 1 \times \cdot / \cdot 1 = \cdot / \cdot \cdot 1$$

$$P(A, O_{1|Y}) = \cdot/Y \times \cdot/Y \wedge Y \wedge A = \cdot/1 \Delta A$$

$$P(B, O_{1|Y}) = \cdot / 4 \times \cdot / \cdot \cdot \lambda \cdot 14 = \cdot / \cdot \cdot VY$$

$$P(A, O_1 | \Upsilon) = \cdot / \Lambda \times \cdot / V \Lambda \Upsilon \Lambda$$

$$P(B, O_{1|r}) = \cdot / 1 \times \cdot / \cdot \cdot 9$$

<u>ج</u>

الگوریتم Backward یکی از روشهای استفاده شده در الگوریتمهای الگوی مخفی مارکوف

(Hidden Markov Models) است. این الگوریتم برای تخمین متغیرهای نهان مدل مارکوف مخفی بر اساس دادههای مشاهده شده استفاده می شود.

در Backward algorithm ، ما به دنبال محاسبه احتمال مشاهده شدن تمام دنباله ها تا یک زمان مشخص در آینده هستیم. برای این کار، از پس بینی (backtracking) برای حساب کردن این احتمالات استفاده می شود.

برای شروع، ما از زمان پایانی به زمان شروع عقب می رویم و در هر مرحله محاسبات خاصی را انجام می دهیم. احتمال پایانی را در زمان پایانی به عنوان شرط اولیه قرار می دهیم و سپس احتمال تمام دنباله ها تا زمان قبلی را محاسبه می کنیم. در این بخش باید احتمال ها را برعکس و از جلو به عقب محاسبه کنیم، پس داریم:

$$P_{\mathbf{r}}(A) = \cdot \wedge \times \cdot \wedge \cdot + \cdot \wedge \cdot =$$

$$P_{\mathbf{r}}(B) = \cdot \wedge \mathbf{A} \times \cdot \wedge \cdot \mathbf{A} + \cdot \wedge \mathbf{A} \times \cdot \wedge \mathbf{A} = \cdot \wedge \mathbf{A} \times \mathbf{A}$$

$$P_{\mathsf{Y}}(A) = \mathsf{INAY} \times \mathsf{INA} + \mathsf{INAX} \times \mathsf{INA} = \mathsf{INAX}$$

$$P_{\mathsf{Y}}(B) = \mathsf{INAY} \times \mathsf{INAY} + \mathsf{INAY} \times \mathsf{INAY} = \mathsf{INAY}$$

$$P_{\mathbf{1}}(A) = \mathbf{1}/\mathbf{1}\Delta\mathbf{1} \times \mathbf{1}/\mathbf{1}\mathbf{1} + \mathbf{1}/\mathbf{1}\Delta\mathbf{1} \times \mathbf{1}/\mathbf{1}$$

$$P_{\mathbf{1}}(B) = \mathbf{1}/\mathbf{1}\Delta\mathbf{1} \times \mathbf{1}/\mathbf{1}\mathbf{1}\Delta\mathbf{1} \times \mathbf{1}/\mathbf{1}\mathbf{1}\Delta\mathbf{1}$$

همان forward است که به جای جمع، ماکسیمم میگیریم پس داریم:

$$P(A, O_1) = \cdot / \Lambda \times \cdot / 44 = \cdot / V4Y$$

$$P(B, O_1) = \cdot / 1 \times \cdot / \cdot 1 = \cdot / \cdot \cdot 1$$

$$P(A, O_{1|Y}) = \cdot/Y \times max(\cdot/Y \wedge Y \cdot \wedge, \cdot/\cdot \cdot \cdot 1) = \cdot/10 \wedge$$

$$P(B, O_{1|Y}) = \cdot/4 \times max(\cdot/\cdot \cdot \vee 4Y, \cdot/\cdot \cdot \cdot 4A) = \cdot/\cdot \cdot \vee$$

$$P(A, O_1 | \Upsilon) = \cdot \wedge \times max(\cdot \wedge \Delta \Upsilon, \cdot \wedge \cdot \wedge)$$

$$P(B, O_{1|Y}) = \cdot/1 \times max(\cdot/\cdot\cdot 1\Delta V, \cdot/\cdot\cdot VAY)$$

سوال ۴.

الف

$$P(\mathit{O}_{\flat} = \mathtt{A}, \mathit{O}_{\mathtt{V}} = \mathtt{A}|S_{\flat} = \mathtt{V}, S_{\mathtt{V}} = \mathtt{A}, \mathit{C}_{\flat} = +, \mathit{C}_{\mathtt{V}} = -) =$$

$$P(\mathcal{O}_{\mathbf{f}} = \mathbf{\Delta}|S_{\mathbf{f}} = \mathbf{V}, C_{\mathbf{f}} = +)P(\mathcal{O}_{\mathbf{V}} = \mathbf{A}|S_{\mathbf{V}} = \mathbf{A}, C_{\mathbf{V}} = -) =$$

$$E(+,\Upsilon)\times E(-,\bullet) = \bullet/\bullet 9$$

و همچنین داریم:

$$P(O_{\mathbf{f}} = \mathbf{D}, O_{\mathbf{V}} = \mathbf{N} | S_{\mathbf{f}} = \mathbf{f}, S_{\mathbf{V}} = \mathbf{f}, C_{\mathbf{f}} = +, C_{\mathbf{V}} = -) =$$

$$E(+, 1) \times E(-, \Upsilon) = \cdot$$

ج

$$P(O_{\mathfrak{S}} = \Delta, O_{\mathsf{V}} = \Lambda | S_{\mathfrak{S}} = \mathsf{V}, S_{\mathsf{V}} = \Lambda) =$$

$$(\cdot/\Delta\times E(+,\Upsilon)+\cdot/\Delta\times E(-,\Upsilon))\times(\cdot/\Delta\times E(+,\bullet)+\cdot/\Delta\times E(-,\bullet))=\cdot/\Delta\times(\cdot/1+\bullet)\times(\cdot/1+\bullet)=\cdot/\cdot\Delta$$
و به طریق مشابه بدست می آوریم:

$$P(O_{\mathfrak{S}} = \Delta, O_{\mathbf{V}} = \Lambda | S_{\mathfrak{S}} = \mathfrak{F}, S_{\mathbf{V}} = \mathfrak{F}) =$$

$$\cdot / \Delta \times (\cdot / \Upsilon + \cdot / \Upsilon) \times (\cdot / \Upsilon + \cdot) = \cdot / \cdot \Upsilon$$

احتمال تبدیل شدن به ذره ی $S_{\rm v}={\cal F}, S_{\rm A}={\cal F}$ برابر با ۱ است. برای حالت دیگر داریم:

$$P(S_{\mathsf{V}} = \mathsf{V}, S_{\mathsf{A}} = \mathsf{P}|S_{\mathsf{P}} = \mathsf{P}, S_{\mathsf{V}} = \mathsf{V}) =$$

$$F(1, \cdot) = \cdot / \Upsilon$$

موفق باشيد.